

Trabalho 1 — Grafos, Redes Aleatórias e Centralidade

Baseado nos Capítulos 1–3 de A.-L. Barabási, *Network Science*, e no módulo de medidas de centralidade do curso.


Instruções gerais

- O trabalho tem 4 questões: 2 teóricas (uma fácil, uma desafiadora) e 2 computacionais (uma fácil, uma desafiadora).
- Questões teóricas: entregar em PDF (digitado ou manuscrito escaneado com boa legibilidade), com todos os passos de raciocínio explícitos — respostas sem justificativa não recebem crédito integral.
- Questões computacionais: entregar um notebook (.ipynb) executado, com código, gráficos e uma célula de texto (markdown) discutindo cada resultado. Gráficos sem discussão também não recebem crédito integral.
- É permitido usar bibliotecas prontas (NetworkX, etc.), mas os relatórios devem demonstrar entendimento do que cada função está calculando — quando pedido explicitamente, implemente o método na mão (sem a função pronta) antes de validar com a biblioteca.
- Trabalho em dupla é permitido; especifique a contribuição de cada integrante ao final.
- Data de entrega: [A DEFINIR] — Peso: [A DEFINIR]

Exercício 1 Grafos e Centralidade — Cálculo Manual

PAPEL E LÁPIS

Considere o grafo abaixo, com 7 nós e 8 arestas, formado por dois grupos densamente conectados (triângulos) ligados por um único nó-ponte P:



- Determine o grau de cada um dos 7 nós do grafo.
- Calcule a centralidade de proximidade (closeness) de cada nó, usando $C(v) = (N-1) / \sum_u d(v,u)$, onde a soma é sobre todos os outros nós u e $d(v,u)$ é a distância (número de arestas do caminho mínimo).
- Calcule a centralidade de intermediação (betweenness) de cada nó: para cada nó v , some, sobre todos os pares (s,t) com $s \neq t \neq v$, a fração de caminhos mínimos entre s e t que passam por v .

- d) Monte uma tabela com o ranking dos 7 nós segundo grau, closeness e betweenness (do maior para o menor, em cada coluna). Existe algum nó cuja posição muda drasticamente entre as três medidas? Explique, em termos da estrutura do grafo, por que isso acontece.
- e) Dê um exemplo do mundo real (fora de redes sociais on-line) de um elemento que teria esse mesmo perfil — grau baixo, mas centralidade de intermediação muito alta. Justifique a analogia em 2–3 frases.

Exercício 2 Redes Aleatórias — O Limiar do Componente Gigante

PAPEL E LÁPIS

Considere o modelo de Erdős–Rényi $G(N, p)$ no regime esparso, com $p = c/N$ e $c = \langle k \rangle$ fixo enquanto $N \rightarrow \infty$. Nesse regime, a vizinhança de um nó, explorada por busca em largura (BFS), pode ser aproximada por um processo de ramificação (branching process): partindo da raiz v , cada nó recém-descoberto "gera", em média, c novos vizinhos ainda não visitados na geração seguinte. Essa é a mesma ideia informal usada por Barabási para justificar a existência do limiar em $\langle k \rangle = 1$.

- a) (Intuição) Em poucas frases, explique por que, quando $p = c/N$, o número esperado de vizinhos ainda não visitados de um nó recém-descoberto é aproximadamente c — independentemente de quantos nós já foram visitados antes — desde que N seja grande e o conjunto já visitado seja pequeno perto de N .
- b) (Cálculo) Suponha que o número esperado de nós na geração d da busca a partir da raiz v seja aproximadamente c^d . Usando essa aproximação, mostre que, se $c < 1$, o tamanho esperado do componente conexo de v — $E[|C(v)|]$, contando a própria raiz — satisfaz:

$$E[|C(v)|] = \sum_{d=0}^{\infty} c^d = 1 / (1 - c)$$

- c) (Interpretação) Explique por que essa mesma soma diverge (deixa de fazer sentido) quando $c > 1$, e o que essa divergência sinaliza fisicamente sobre a estrutura da rede nesse regime.
- d) (Conclusão) Argumente por que $E[|C(v)|]$ permanecer limitado — isto é, não crescer com N — quando $c < 1$ já basta para concluir que não pode existir, nesse regime, um componente gigante (um componente cujo tamanho seja uma fração positiva αN de todos os nós, com $\alpha > 0$ fixo).

Exercício 3 Simulando a Transição de Fase de Erdős–Rényi

COMPUTACIONAL

Neste exercício você vai reproduzir, computacionalmente, o mesmo fenômeno discutido no Exercício 2 — na linha dos exercícios computacionais propostos no próprio livro-texto (Barabási, *Network Science*, Cap. 3, seção de Homework, disponível gratuitamente em networksciencebook.com).

- a) Fixe $N = 5000$ (ou outro valor grande o suficiente para os efeitos ficarem visíveis) e gere redes de Erdős–Rényi $G(N, p)$ para pelo menos 8 valores de $\langle k \rangle = p(N-1)$, cobrindo o intervalo de 0,2 a 8 (por exemplo: 0,2 / 0,5 / 0,8 / 1 / 1,5 / 2 / 4 / 8).
- b) Para cada valor de $\langle k \rangle$, calcule o tamanho do maior componente conexo (como fração de N) e plote esse valor em função de $\langle k \rangle$. Você deve observar a transição de fase próxima de $\langle k \rangle = 1$ discutida no Exercício 2.
- c) Fixando $\langle k \rangle = 8$, gere redes com N crescente (por exemplo: 100, 300, 1000, 3000, 10000) e calcule o caminho médio (average shortest path length) dentro do maior componente de cada rede. Plote seu resultado contra a previsão teórica $\langle d \rangle \approx \ln(N)/\ln(\langle k \rangle)$ em função de N (uma escala logarítmica no eixo N ajuda a visualizar).

- d) Ainda com $\langle k \rangle = 8$ e $N = 5000$, plote o histograma da distribuição de grau da rede aleatória gerada e compare, no mesmo gráfico, com a distribuição de grau da rede de resultados da FIFA usada no Exercício 4. Comente: a rede aleatória produz "hubs" comparáveis aos observados na rede real? O que essa diferença sugere sobre os limites do modelo de Erdős–Rényi para representar redes do mundo real? (Você não precisa resolver esse problema agora — é uma reflexão que antecipa o próximo tópico do curso.)

Exercício 4 A Rede de Resultados da FIFA — Centralidade e PageRank Personalizado

COMPUTACIONAL

A base de dados fornecida (arquivo .csv com colunas Source, Target, Weight) representa um grafo dirigido e ponderado: uma aresta de A para B significa que a seleção A perdeu para a seleção B; um empate gera uma aresta em cada direção; o peso reflete a importância da partida (por exemplo, uma final de Copa do Mundo pesa mais do que um amistoso).

- a) Descreva a rede: quantos nós (seleções) e arestas (confrontos) ela tem? Ela é (fracamente/fortemente) conexa? Qual seleção tem o maior grau de entrada simples (contagem bruta de vitórias, sem ponderar)?
- b) Calcule a centralidade autovetor, a centralidade de Katz e o PageRank — todas ponderadas pelo peso da aresta — para todas as seleções. Monte uma tabela com o Top 10 de cada medida. As três concordam no topo do ranking? Onde discordam, e por quê? (Lembre-se: as três compartilham a mesma ideia recursiva — "importância flui de quem perde para quem vence" — mas diferem em como tratam atenuação e normalização; vale revisitar a relação $\text{Katz} \leftrightarrow \text{PageRank}$ vista em aula.)
- c) Questão crítica. A distinção hub/autoridade do HITS foi pensada originalmente para a Web, onde uma página tende a ser predominantemente hub (uma lista de links) ou predominantemente autoridade (um conteúdo referenciado). Nesta rede de futebol, cada seleção desempenha os dois papéis ao mesmo tempo — perde às vezes, vence às vezes. Calcule ainda assim os escores de hub e de autoridade do HITS. Eles trazem alguma informação que o PageRank/eigenvector não trazem, ou a distinção hub/autoridade simplesmente colapsa nessa rede? Justifique com base nos resultados obtidos — não apenas na teoria.
- d) PageRank Personalizado. Calcule o PageRank personalizado em duas variantes e compare ambas com o Top 10 do PageRank global do item (b):
- Escolha uma seleção X (por exemplo, o Brasil) e calcule o PageRank personalizado com o vetor de teletransporte concentrado 100% em X (parâmetro personalization do NetworkX, ou implementação própria via iteração de potência).
 - Escolha agora uma confederação inteira (por exemplo, a CONMEBOL ou a CONCACAF) e calcule o PageRank personalizado com o vetor de teletransporte distribuído entre todas as seleções dessa confederação (você decide se a distribuição será uniforme entre elas ou ponderada por algum critério — justifique sua escolha).

Para as duas variantes, discuta:

Quais seleções aparecem no ranking personalizado que não apareciam no ranking global? O que essa diferença captura, em termos de "ameaça específica" (no caso i) ou "relevância regional" (no caso ii), que o ranking global — voltado à seleção/região mais forte do mundo em geral — não captura?

Compare os dois rankings personalizados entre si (item i vs. item ii). O ranking da confederação inteira (ii) se aproxima mais do ranking individual (i) ou do ranking global (b)? Sob qual condição você esperaria que a personalização por confederação ficasse praticamente indistinguível do PageRank global? (Dica: pense no que acontece quando o conjunto de teletransporte cresce até incluir todas as seleções.)

Esse é o mesmo princípio por trás de sistemas de recomendação personalizados no mundo real — por exemplo, o antigo algoritmo "Who to Follow" do Twitter, ou o sistema Pixie do Pinterest: a importância de um nó não é absoluta, é relativa a um ponto de partida, que pode ser tanto um indivíduo quanto um grupo/interesse inteiro (essa ideia mais geral é conhecida como PageRank tópico-sensível, de Haveliwala, 2002).

e) Limitações. Aponte pelo menos duas limitações dessa rede/abordagem como medida de "força" de uma seleção (por exemplo: ausência de ponderação por recência dos jogos, efeito de mando de campo não considerado, margem de vitória/número de gols ignorado, viés de calendário — seleções que jogam mais partidas contra adversários fracos ou fortes). Escolha uma dessas limitações e proponha, em termos concretos, como você tentaria corrigi-la nesse mesmo arcabouço de centralidade em grafos.